จัดกลุ่มลูกค้าด้วย K-Means

ฝึกโมเดลด้วยข้อมูลชุดฝึก แล้วจัดกลุ่มลูกค้าใหม่ในข้อมูลชุดทดสอบ

ชื่อ-สกุล _____ รหัสนักศึกษา _____

รายวิชา _____ กลุ่มเรียน _____ วันที่ _____

1 จุดประสงค์

นักศึกษาต่อบล็อกใน ThaiPyBlocks เพื่อแบ่งลูกค้าเป็น **ชุดฝึก (train)** กับ **ชุดทดสอบ (test)** ให้ K-Means หากลุ่มจากชุดฝึก แล้วตรวจว่ากลุ่มที่ได้ใช้กับลูกค้าที่โมเดลไม่เคยเห็นได้ ทุกบล็อกคือคำสั่ง Python (pandas · scikit-learn) จริง ดูได้ในแท็บ "โค้ด Python"

เมื่อทำใบงานเสร็จ นักศึกษาจะ

- อธิบายได้ว่าทำไมต้องแยกชุดทดสอบไว้ก่อนฝึกโมเดล และใช้บล็อก `train_test_split` ได้
- ฝึก K-Means กับชุดฝึก แล้วจัดลูกค้าในชุดทดสอบเข้ากลุ่มที่เรียนได้
- เลือกจำนวนกลุ่ม k ด้วยวิธี elbow และวัดคุณภาพกลุ่มด้วยค่า silhouette (−1 ถึง 1 ยิ่งใกล้ 1 กลุ่มยิ่งแยกกันชัด)

2 สิ่งที่ต้องเตรียม

1. เปิดแอป ThaiPyBlocks จากลิงก์ที่ผู้สอนให้ บนคอมพิวเตอร์หรือแท็บเล็ต (จอกว้างต่อบล็อกได้สะดวกกว่า) ลิงก์ _____
2. ดาวน์โหลดไฟล์ `mall_customers.csv` จากผู้สอน
3. ในแอปกด **ข้อมูลของฉัน** → **เลือกไฟล์** (หรือลากไฟล์มาวาง) แอปแสดงจำนวนแถว คอลัมน์ และ 5 แถวแรกให้ตรวจว่าอ่านไฟล์ถูก
4. กดเมนู ⋯ → **ล้างพื้นที่ทำงาน** แล้วเริ่มต่อบล็อกใหม่ แตะบล็อกเพื่อดูคำสั่ง Python และความหมายภาษาไทยด้านล่าง
5. **ส่งงาน**: ใบงานนี้ที่กรอกตารางและตอบคำถามครบ พร้อมไฟล์ PDF จากปุ่ม **PDF** ในแท็บผลลัพธ์ของแอป (รันด้วยค่าตามใบงาน k = 5 ก่อนกด PDF)

ไฟล์ที่อัปโหลดอยู่ในเครื่องของนักศึกษาเท่านั้น ถ้ารีโหลดหน้าต้องอัปโหลดใหม่ (บล็อกที่ต่อไว้ไม่หาย)

3 ข้อมูล: ลูกค้าห้างสรรพสินค้า 200 คน

ไฟล์ `mall_customers.csv` เป็นข้อมูลจำลองเพื่อการสอน ลูกค้าแบ่งเป็น 5 กลุ่มตามรายได้และการใช้จ่าย แต่ไฟล์ไม่มีคอลัมน์บอกกลุ่ม โมเดลต้องหาเอง กิจกรรมใช้เฉพาะ income กับ spending ซึ่งมีช่วงค่าใกล้กัน จึงไม่ต้องปรับสเกลก่อนใช้ K-Means

คอลัมน์	ความหมาย	ค่าในไฟล์
`customer_id`	รหัสลูกค้า	C001–C200
`gender`	เพศ	หญิง 103 คน, ชาย 97 คน
`age`	อายุ (ปี)	18–70
`income`	รายได้ต่อเดือน (พันบาท)	16–108
`spending`	คะแนนการใช้จ่ายที่ห้างให้ ยิ่งมากยิ่งซื้อบ่อยและซื้อมาก	1–99

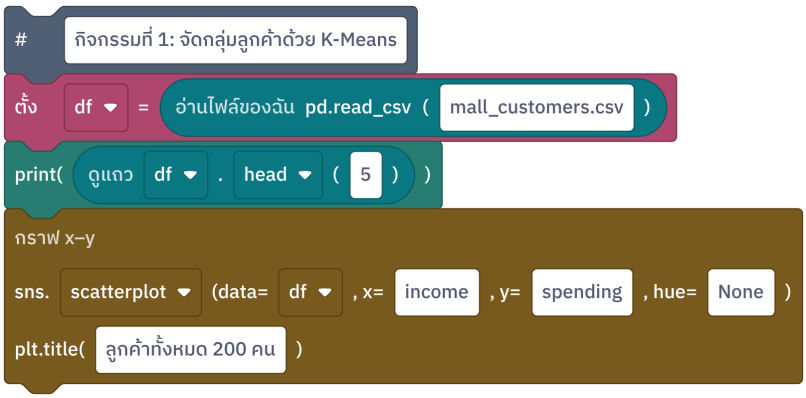
4 ขั้นตอนการต่อบล็อก

กด ▶ รัน ได้ทุกเมื่อ แอปรันใหม่ตั้งแต่บล็อกแรก หลังรันครั้งแรก ช่องชื่อคอลัมน์จะมีรายการให้เลือก เปลี่ยนชื่อตัวแปรได้ที่ลูกศร ▾ ของตัวแปร → เปลี่ยนชื่อตัวแปร...

■ **ข้อมูล › โหลด & สำรวจ** = หมวดบล็อกในแถบซ้าย (สีเดียวกับในแอป) **ตั้ง df = อ่านไฟล์ของฉัน** = บล็อกที่ลากมาต่อ

ตอนที่ 1 โหลดและดูข้อมูล

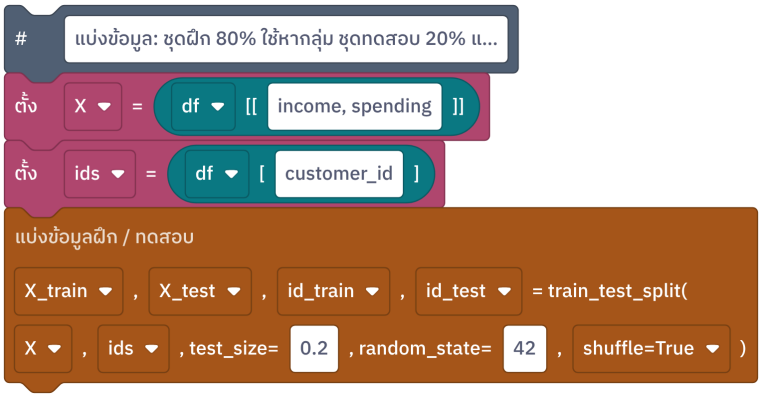
1. ■ **ข้อมูล › โหลด & สำรวจ** ลาก **ตั้ง df = อ่านไฟล์ของฉัน** มาวาง กดช่อง "เลือกไฟล์..." แล้วเลือก `mall_customers.csv`
2. ต่อ **print(ดูแถว df.head(5))** จากหมวดเดียวกัน
3. ■ **กราฟ** ต่อ **กราฟ x–y** เลือก scatterplot, data = df, x = income, y = spending, hue เว้นว่าง
4. กด ▶ รัน ต้องเห็นตาราง 5 แถวและกราฟจุด 200 จุด



บล็อกของตอนนี้เมื่อต่อเสร็จ ใช้ตรวจลำดับของตนเอง

ตอนที่ 2 แบ่งชุดฝึก / ชุดทดสอบ

1. ■ **เตรียมข้อมูล** ลาก **ตั้ง X = ...** มาวาง เปลี่ยนค่าทางขวาเป็น **df[[ ]]** จาก ■ **ข้อมูล › เลือก & กรอง** แล้วเลือก income, spending
2. ■ **เตรียมข้อมูล** ลาก **ตั้ง y = df[ ]** เลือก customer_id แล้วเปลี่ยนชื่อตัวแปร y เป็น `ids`
3. ■ **เตรียมข้อมูล** ต่อ **แบ่งข้อมูลฝึก / ทดสอบ** ตั้งค่า X, ids, test_size = 0.2, random_state = 42 เลือก shuffle=True (ไม่ใช้ stratify เพราะไม่มีคลาส) และเปลี่ยนชื่อ y_train, y_test เป็น id_train, id_test
4. กด ▶ รัน ต้องเห็นข้อความ "train 160 แถว · test 40 แถว"



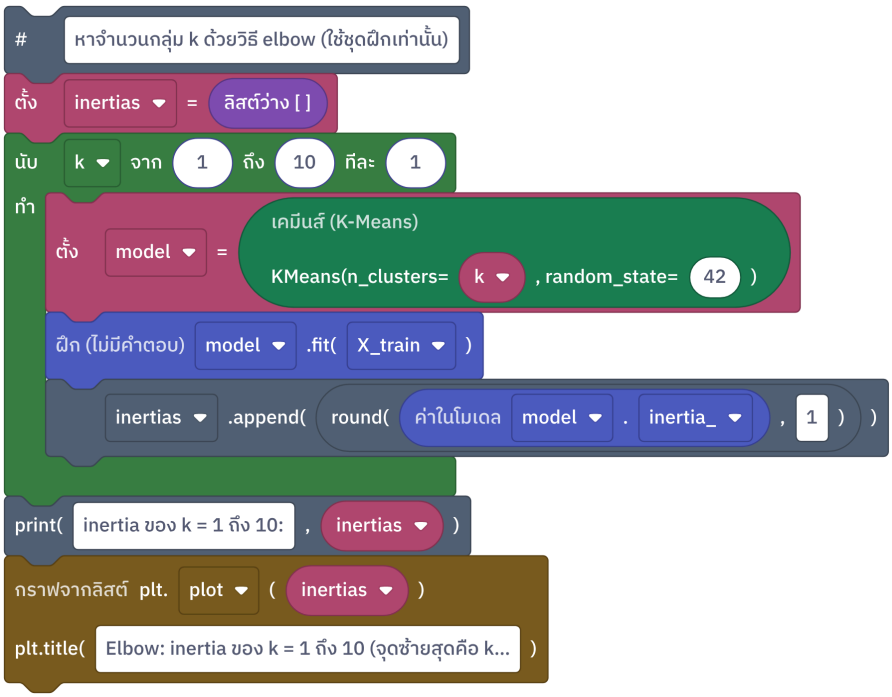
บล็อกของตอนนี้เมื่อต่อเสร็จ ใช้ตรวจลำดับของตนเอง

โค้ด Python ที่ได้ (รหัสลูกค้าไม่ได้ใช้ฝึก แต่บอกว่าลูกค้าคนไหนอยู่ชุดใด)

```
X_train, X_test, id_train, id_test = train_test_split(X, ids, test_size=0.2,
random_state=42)
```

ตอนที่ 3 หาจำนวนกลุ่ม k ด้วยวิธี elbow (ใช้ชุดฝึกเท่านั้น)

1. ■ **Python › ตัวแปร** กด สร้างตัวแปร... ชื่อ `inertias` ลาก **ตั้ง inertias =** มาต่อ แล้วใส่ **ลิสต์ว่าง [ ]** จาก ■ **Python › ลิสต์**
2. ■ **Python › ลูป** ต่อ **นับ i จาก 1 ถึง 10 ทีละ 1** แล้วเปลี่ยนชื่อ i เป็น `k`
3. ในช่อง "ทำ" ของลูป ใส่ 3 บล็อกตามลำดับ
   - ■ **โมเดล › จัดกลุ่ม & ลดมิติ** **ตั้ง model = KMeans(...)** แล้วลากตัวแปร k มาวางทับเลข n_clusters
   - ■ **ฝึก & ทำนาย** **ฝึก (ไม่มีคำตอบ) model.fit( )** เลือก X_train
   - ■ **Python › แสดงผล** **.append( )** เลือก inertias ใส่ **round(, 1)** แล้วใส่ **ค่าในโมเดล model . inertia_** ไว้ใน round
4. ใต้ลูป ต่อ **print(ผลลัพธ์: , ...)** แก้ข้อความเป็น `inertia ของ k = 1 ถึง 10:` แล้วใส่ตัวแปร inertias
5. ■ **กราฟ** ต่อ **กราฟจากลิสต์** แบบ plot ใส่ inertias
6. กด ▶ รัน บันทึกค่าลงตารางที่ 1 จุดซ้ายสุดของกราฟคือ k = 1 แล้วหา "ข้อศอก" ที่เส้นเริ่มแบนราบ

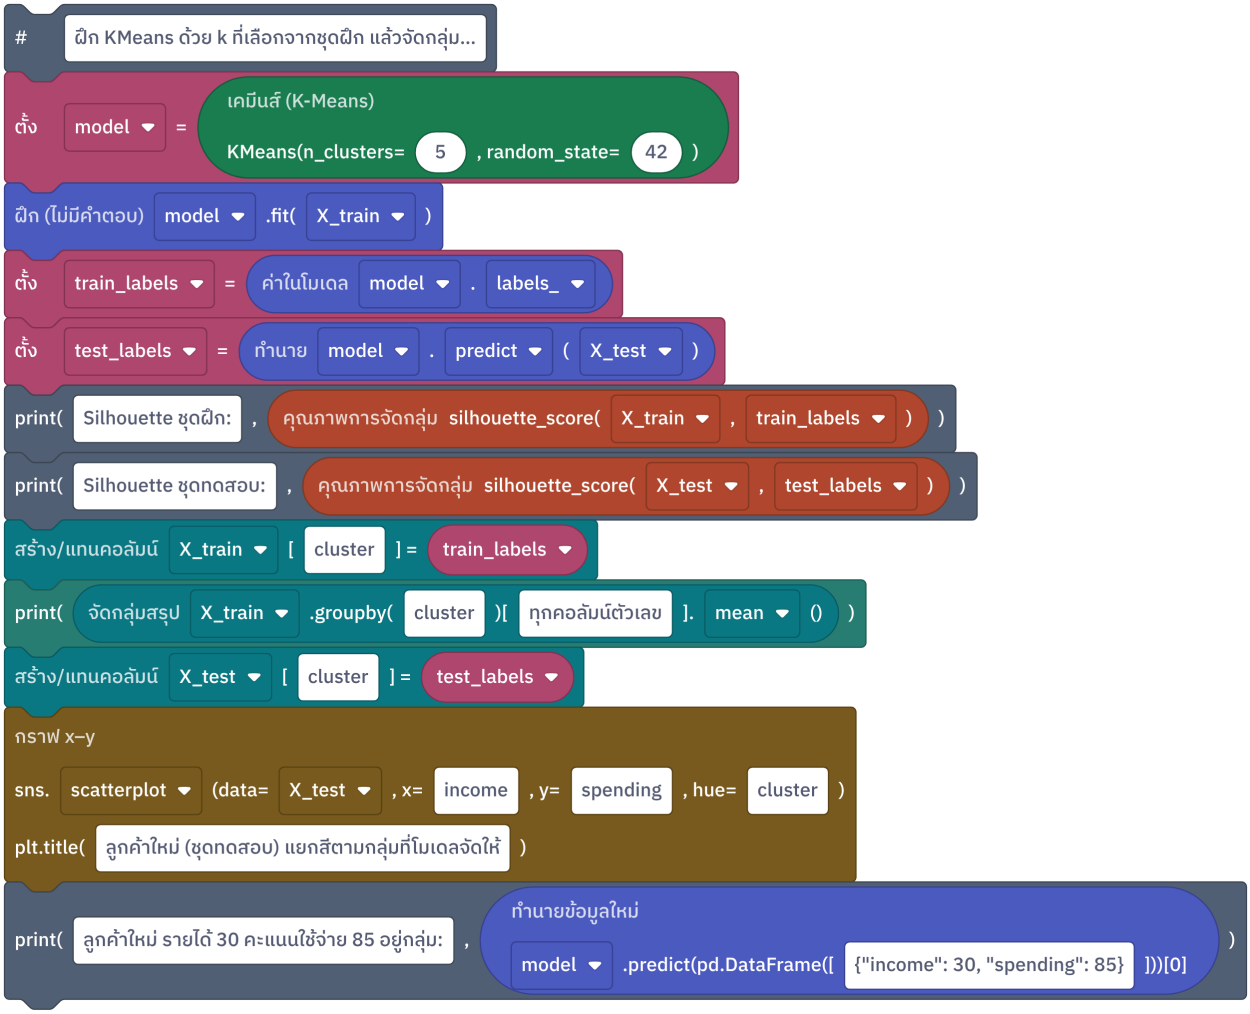


บล็อกของตอนนี้เมื่อต่อเสร็จ ใช้ตรวจลำดับของตนเอง

ตอนที่ 4 ฝึกด้วยชุดฝึก แล้วจัดกลุ่มลูกค้าใหม่ในชุดทดสอบ

1. ต่อ **ตั้ง model = KMeans(...)** อีกครั้งใต้กราฟ (นอกลูป) ใส่ n_clusters = k ที่เลือกจากข้อศอก แล้วต่อ **ฝึก (ไม่มีคำตอบ) model.fit(X_train)**
2. สร้างตัวแปร `train_labels` แล้วต่อ **ตั้ง train_labels = ค่าในโมเดล model . labels_**
3. ■ **ฝึก & ทำนาย** ต่อ **ตั้ง y_pred = ทำนาย model.predict(X_test)** แล้วเปลี่ยนชื่อ y_pred เป็น `test_labels`
4. ■ **วัดผล** ใส่ **คุณภาพการจัดกลุ่ม silhouette_score(,)** ลงใน **print(,)** 2 บล็อก: ข้อความ `Silhouette ชุดฝึก:` กับ X_train, train_labels และ `Silhouette ชุดทดสอบ:` กับ X_test, test_labels
5. ■ **ข้อมูล › คำนวณคอลัมน์** **สร้าง/แทนคอลัมน์** เลือก X_train ชื่อคอลัมน์ cluster ใส่ train_labels แล้วต่อ **print(จัดกลุ่มสรุป X_train.groupby(cluster) ... mean())** จาก ■ **ข้อมูล › เลือก & กรอง** โดยเว้นช่องคอลัมน์ว่าง (= ทุกคอลัมน์ตัวเลข)
6. ต่อ **สร้าง/แทนคอลัมน์** อีกบล็อก เลือก X_test ชื่อ cluster ใส่ test_labels แล้วต่อ **กราฟ x–y** data = X_test, x = income, y = spending, hue = cluster
7. ■ **ฝึก & ทำนาย › ใช้งานโมเดล** ใส่ **ทำนายข้อมูลใหม่** ลงใน print แก้ค่าเป็น `{"income": 30, "spending": 85}`
8. กด ▶ รัน แล้วกดปุ่ม PDF เก็บผล

ลำดับในตอนที่ 4 สำคัญ ต้องทำนายและวัด silhouette ก่อนเพิ่มคอลัมน์ cluster ถ้าเพิ่มก่อน บล็อกทำนายจะแจ้งข้อผิดพลาด (ข้อมูลมี 3 คอลัมน์ แต่โมเดลฝึกมา 2 คอลัมน์) และ silhouette จะนับ cluster เป็นฟีเจอร์ด้วยจนค่าผิด



บล็อกของตอนนี้เมื่อต่อเสร็จ ใช้ตรวจลำดับของตนเอง

5 ตารางบันทึกผล

บันทึกทศนิยม 3 ตำแหน่ง (เช่น 0.704) ทุกครั้งที่แก้ค่าในบล็อก ต้องกด ▶ รัน ใหม่ก่อนอ่านผล ทดลองเสร็จแล้วคืนค่าเดิมก่อนทำตารางถัดไป

ตารางที่ 1 inertia ของ k = 1–10

ตอนที่ 3: คัดจากบรรทัด "inertia ของ k = 1 ถึง 10" ตามลำดับ แล้วหาว่าแต่ละ k ลดลงจากค่าก่อนหน้าเท่าไร

k	inertia	ลดลงจาก k ก่อนหน้า
1		–
2		
3		
4		
5		
6		
7		
8		
9		
10		

ข้อศอกของกราฟอยู่ที่ k = _____

ตารางที่ 2 จำนวนกลุ่มกับคุณภาพการจัดกลุ่ม

แก้ n_clusters ในบล็อก KMeans ที่อยู่นอกลูปเป็น 3, 4, 5, 6 ทีละค่า แล้วรัน

k	Silhouette ชุดฝึก	Silhouette ชุดทดสอบ
3		
4		
5		
6		

ตารางที่ 3 ตั้งชื่อกลุ่มลูกค้า (k = 5)

คัดค่าเฉลี่ยจากตาราง groupby แล้วตั้งชื่อกลุ่ม เช่น "รายได้สูง ใช้จ่ายน้อย"

cluster	income เฉลี่ย (พันบาท)	spending เฉลี่ย	ชื่อกลุ่ม
0			
1			
2			
3			
4			

ตารางที่ 4 เปลี่ยนวิธีแบ่งข้อมูล (k = 5)

แก้ test_size หรือ random_state ในบล็อกแบ่งข้อมูลตามแถว แล้วรัน

test_size	random_state	แถว ฝึก / ทดสอบ	Silhouette ชุดฝึก	Silhouette ชุดทดสอบ	ลูกค้าใหม่ (30, 85) อยู่กลุ่ม
0.2	42				
0.2	7				
0.5	42				

6 คำถามท้ายใบงาน

ตอบสั้น ๆ พร้อมอ้างตัวเลขจากตาราง

1 กราฟจุดในตอนที่ 1 เห็นลูกค้ากี่กลุ่ม ตรงกับ k ที่ข้อศอกของตารางที่ 1 หรือไม่

2 ทำไมต้องหา k และฝึก KMeans ด้วยชุดฝึกเท่านั้น ถ้าใช้ลูกค้าทั้ง 200 คนฝึก จะรู้ได้อย่างไรว่ากลุ่มที่ได้ใช้กับลูกค้าใหม่ได้

3 ตารางที่ 2: ถ้าเลือก k จาก Silhouette ชุดทดสอบ จะได้ k เท่าไร ต่างจากชุดฝึกหรือไม่ ควรใช้ชุดไหนเลือก k เพราะอะไร

4 ตารางที่ 4: เลขกลุ่มของลูกค้าใหม่เปลี่ยนไปตามการแบ่งข้อมูล แปลว่าเขาย้ายกลุ่มจริงหรือไม่ เขาเป็นลูกค้ากลุ่มไหนในตารางที่ 3 และห้างควรเสนออะไรให้เขา